

# Apprentissage fédéré

Vers du Deep Learning plus respectueux de la vie privée ?



# Plan de l'oral

1. Données décentralisées, que faire ?
2. Introduction à l'apprentissage fédéré
3. Etude de cas : Google GBoard
4. Vraiment respectueux de la vie privée ?
5. Pistes d'améliorations du secteur

# 1. Données décentralisées, que faire ?

# I. Données décentralisées, que faire ?

## Pourquoi des données décentralisées ?


→ Omniprésence d'appareils connectés



# I. Données décentralisées, que faire ?

## Pourquoi des données décentralisées ?

- Omniprésence d'appareils connectés
- Beaucoup de données générées (1h de véhicule connecté ~ 25go)
- Données éparpillées chez les clients finaux
- Sensible par nature






# I. Données décentralisées, que faire ?

## Quelles sont ces données décentralisées ?

- Texte des SMS, photos de la galerie, localisation d'un téléphone
- Données d'utilisation d'applications, enregistrements de la voix "dis Siri"
- Données LIDAR ou caméra
- Données médicales



# I. Données décentralisées, que faire ?

## Quelles sont ces données décentralisées ?

- Texte des SMS, photos de la galerie, localisation d'un téléphone
- Données d'utilisation d'applications, enregistrements de la voix "dis Siri"
- Données LIDAR ou caméra
- Données médicales

Caractéristiques de ces données décentralisées :

- **Données précieuses d'un point de vue marketing : il FAUT les exploiter**

# I. Données décentralisées, que faire ?

## Quelles sont ces données décentralisées ?

- Texte des SMS, photos de la galerie, localisation d'un téléphone
- Données d'utilisation d'applications, enregistrements de la voix "dis Siri"
- Données LIDAR ou caméra
- Données médicales

Caractéristiques de ces données décentralisées :

- **Données précieuses d'un point de vue marketing : il FAUT les exploiter**
- **MAIS problème : il est très intrusif de les extraire de leur endroit de stockage !**



# I. Données décentralisées, que faire ?

## Quelles sont ces données décentralisées ?

- Texte des SMS, photos de la galerie, localisation d'un téléphone
- Données d'utilisation d'applications, enregistrements de la voix "dis Siri"
- Données LIDAR ou caméra
- Données médicales


### Caractéristiques de ces données décentralisées :

- Données précieuses d'un point de vue marketing : il FAUT les exploiter
- MAIS problème : il est très intrusif de les extraire de leur endroit de stockage !

**Enjeu : trouver une façon de traiter ces données, en respectant la vie privée des utilisateurs finaux !**

# I. Données décentralisées, que faire ?

## Apprentissage local



**Première idée** : les données restent en local

Un modèle de Machine Learning est appris sur chaque appareil décentralisé avec les données locales

- + **Avantages** :
  - la vie privée est respectée, aucune fuite de données
  - pas de communication entre appareils décentralisés -> empreinte carbone plus faible
- **Inconvénients** :
  - pas forcément suffisamment de données en local pour du Deep Learning
  - ne tire pas parti des données des autres appareils décentralisés

# I. Données décentralisées, que faire ?


## Apprentissage centralisé

**Seconde idée** : les données sont transmises à un serveur centralisé

données transférées au serveur

modèle appris au niveau du serveur sur ces données

modèle transféré aux appareils décentralisés



+ **Avantages** :

- beaucoup de données : apprentissage facile
- tire parti des données de tous les appareils décentralisés

- **Inconvénients** :

- données privées transférées !!!!!
- utilisation de beaucoup de bande passante : mauvaise empreinte écologique
- forte latence

# I. Données décentralisées, que faire ?

Apprentissage fédéré, le meilleur des deux mondes ?

	Local	Centralisé
<b>Avantages</b>	Faible bande passante Respect vie privée	Tire efficacement parti des données
<b>Inconvénients</b>	N'exploite pas les données de chaque appareil peu de données	Forte bande passante Non respect vie privée latence

Google en 2017 : Federated Learning

=> Contrecarre les défaillances des deux techniques précédentes

# 2.

## Introduction à l'apprentissage fédéré

# II. Introduction à l'apprentissage fédéré

## Rappels de Machine Learning

**Contexte** : apprentissage supervisé, réseaux de neurones

Tâche	Entrée	Label
Classification d'images		3
Prédiction du prochain mot	Le réveil a été ?	difficile
Jeu de go		prochain mouvement

**But** : apprendre à partir des données une fonction  $f$ , paramétrée par un vecteur de paramètres  $\mathbf{W}$ , telle que  $f(\text{entrée}) \approx \text{label}$



# II. Introduction à l'apprentissage fédéré

## Rappels de Machine Learning

**Contexte** : apprentissage supervisé, réseaux de neurones

**But** : apprendre à partir des données une fonction **f**, paramétrée par un vecteur de paramètres **W**, telle que  $f(\text{entrée}) \approx \text{label}$

Ici, la fonction **f** est un réseau de neurones  
=> entre 10 et 500M paramètres, voire +

Vocabulaire :


**client** = appareil avec donnée décentralisée

**serveur**

## II. Introduction à l'apprentissage fédéré

### Apprentissage fédéré

Apprendre au niveau du serveur, un modèle à partir des données des clients, sans avoir accès aux données



<https://ai.googleblog.com/2017/04/federated-learning-collaborative.html>

# II. Introduction à l'apprentissage fédéré

**Algorithm 1** FederatedAveraging targeting updates from  $K$  clients per round.

**Server executes:**

```
initialize  $w_0$ 
for each round  $t = 1, 2, \dots$  do
    Select  $1.3K$  eligible clients to compute updates
    Wait for updates from  $K$  clients (indexed  $1, \dots, K$ )
     $(\Delta^k, n^k) = \text{ClientUpdate}(w)$  from client  $k \in [K]$ .
     $\bar{w}_t = \sum_k \Delta^k$  // Sum of weighted updates
     $\bar{n}_t = \sum_k n^k$  // Sum of weights
     $\Delta_t = \bar{\Delta}_t / \bar{n}_t$  // Average update
     $w_{t+1} \leftarrow w_t + \Delta_t$ 
```

**ClientUpdate( $w$ ):**

```
 $\mathcal{B} \leftarrow$  (local data divided into minibatches)
 $n \leftarrow |\mathcal{B}|$  // Update weight
 $w_{\text{init}} \leftarrow w$ 
for batch  $b \in \mathcal{B}$  do
     $w \leftarrow w - \eta \nabla \ell(w; b)$ 
 $\Delta \leftarrow n \cdot (w - w_{\text{init}})$  // Weighted update
// Note  $\Delta$  is more amenable to compression than  $w$ 
return  $(\Delta, n)$  to server
```

**Paramètres :**


- Nombre de rounds  $R$
- Nombre d'épochs de mise à jour locale  $E$
- Taille des batchs  $B$
- Fraction de clients sélectionnés à chaque round  $C$

+ **Avantages :**

- tire parti des données de tous les appareils décentralisés
- respecte la vie privée
- bande passante faible => impact CO<sup>2</sup> réduit

- **Inconvénients :**

- À venir



## II. Introduction à l'apprentissage fédéré

### Acteurs majeurs de l'apprentissage fédéré

- Google : GBoard, fonction "Hey Google", († FLoC) 
- Apple : "Dis Siri", QuickType, "trouvé dans l'application" 
- Facebook, Amazon, Microsoft   
- Samsung, Huawei  
- IBM 
- Nvidia 
- Owkin (biotech franco-américaine avec données hospitalières) 

## **II. Introduction à l'apprentissage fédéré**

### Usages actuels de l'apprentissage fédéré

- Amélioration de fonctions internes du téléphone
- Véhicules intelligents et connectés
- Données d'institutions (en particulier hospitalières, bancaires ou d'assurance)

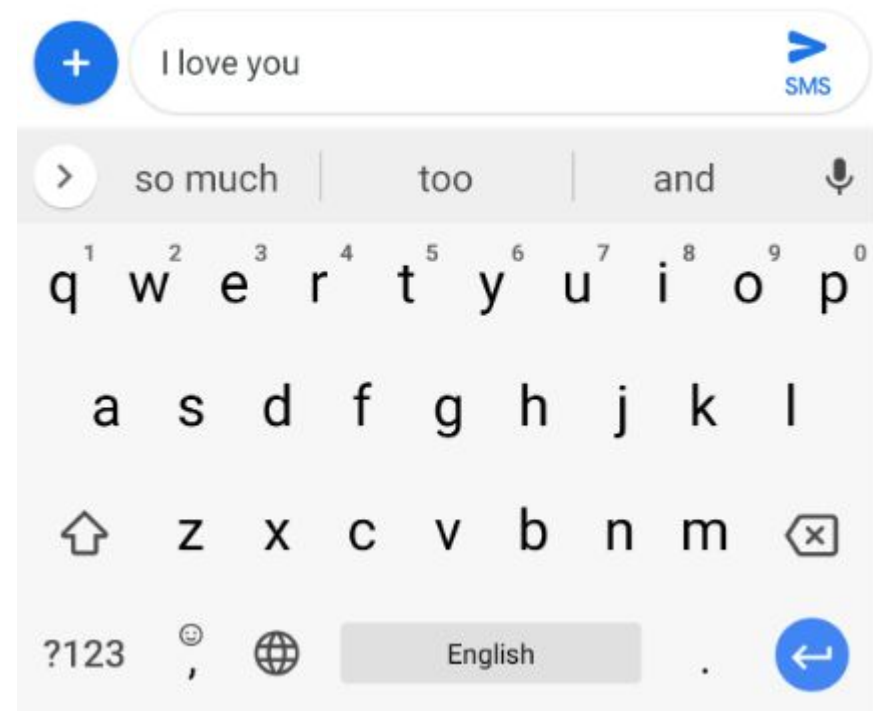
# **3. Etude de cas : Google GBoard**



# III. Etude de cas : Google GBoard

## Contexte

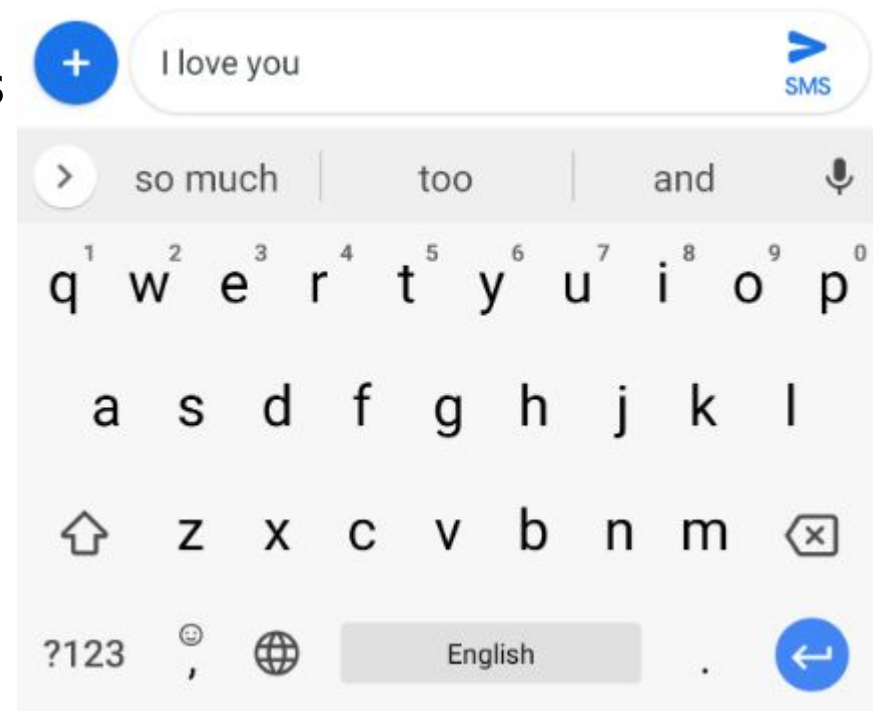
- 2 Mds appareils Android dans le monde



# III. Etude de cas : Google GBoard

## Contexte


- 2 Mds appareils Android dans le monde
- données naturellement labellisées : chaque phrase écrite peut être utilisée pour l'entraînement du modèle



# III. Etude de cas : Google GBoard

## Contexte

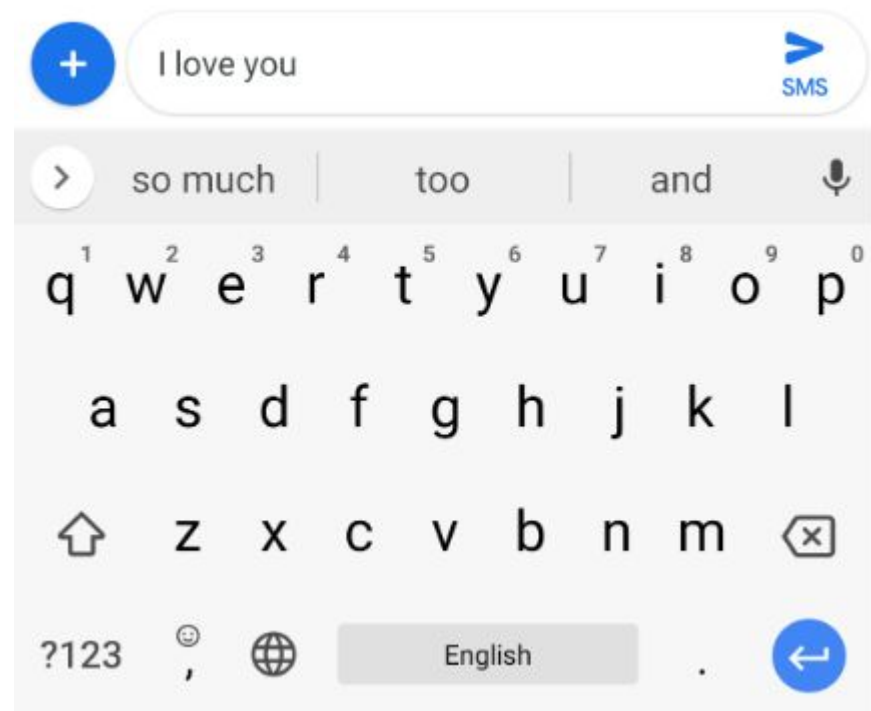

- 2 Mds appareils Android dans le monde
- données naturellement labellisées : chaque phrase écrite peut être utilisée pour l'entraînement du modèle
- Appareils peu fiables : les appareils qui contribuent à l'entraînement peuvent se déconnecter à tout moment



# III. Etude de cas : Google GBoard

## Contexte

- 2 Mds appareils Android dans le monde
- données naturellement labellisées : chaque phrase écrite peut être utilisée pour l'entraînement du modèle
- Appareils peu fiables : les appareils qui contribuent à l'entraînement peuvent se déconnecter à tout moment
- LSTM : 1.4M params  
3000 rounds  
100 clients par round  
80 clients minimum



# III. Etude de cas : Google GBoard

## Sélection des clients

- Entraînement local : téléphone branché + connecté au WiFi
- 6 à 10% des clients se déconnectent
- Le modèle est d'abord évalué, puis entraîné sur les données locales
- Mêmes performances que le modèle centralisé

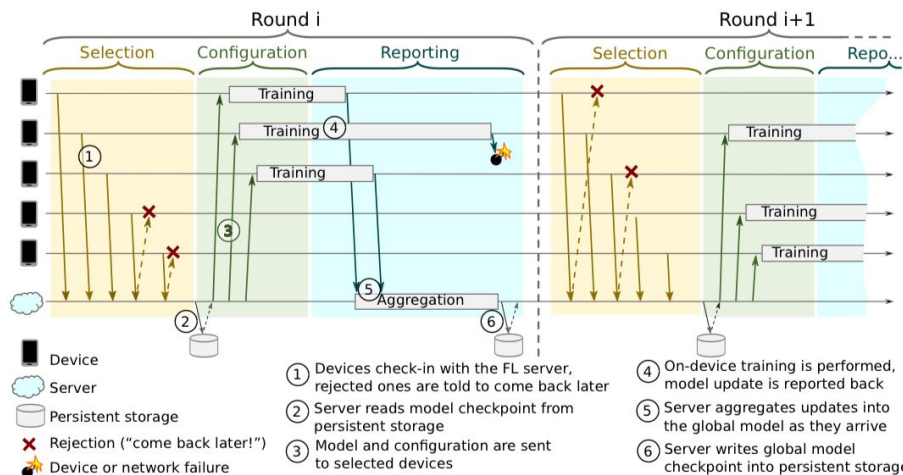
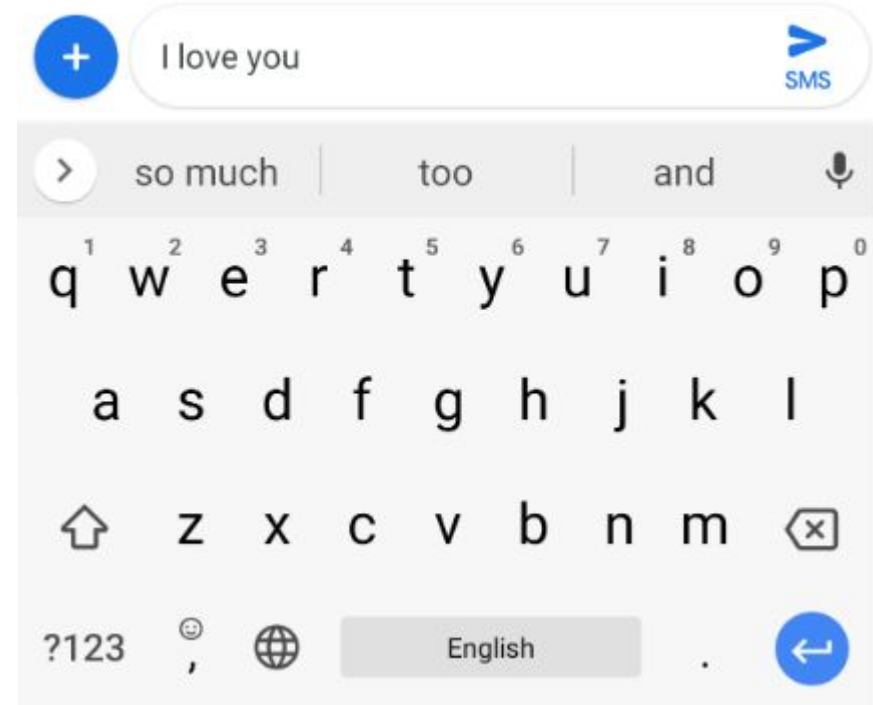


Figure 1: Federated Learning Protocol



# III. Etude de cas : Google GBoard

## Contexte

**Poids** : 145M de scalaires

Valeurs faibles -> mises à 0

Quantization des valeurs des paramètres

approximation de rang faible des poids

Codage de Huffman

Compression d'un facteur 50-100

*(Federated Learning : Strategies for Improving Communication Efficiency)*



# **4. Vraiment respectueux de la vie privée ?**

# IV. Vraiment respectueux de la vie privée?

## Inversion des gradients



Original batch - ground truth



GradInversion (Ours) - LPIPS ↓: 0.484

A partir des mises à jour faites par les clients, il est possible de reconstruire les données d'entraînement !

=> Nécessité de cryptographie pour protéger cette information


*(Federated Learning : Strategies for Improving Communication Efficiency)*

# IV. Vraiment respectueux de la vie privée?

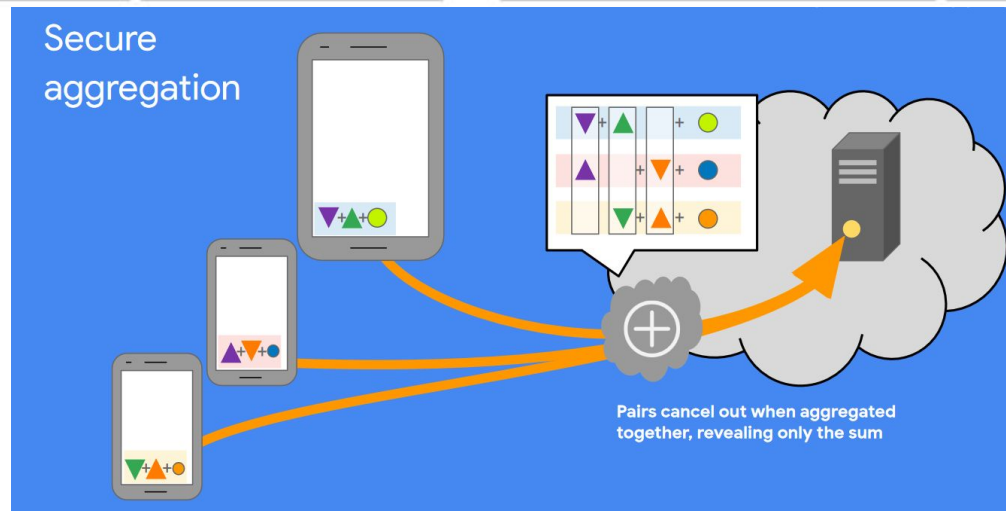

## Secure aggregation

=> Nécessité de cryptographie pour protéger cette information

Federated Learning



Federated Learning with Secure Aggregation



# 5. Pistes d'améliorations du secteur

# V. Pistes d'amélioration du secteur

## Equité et données non-iid

- apprentissage fédéré = collaboration
- au niveau des utilisateurs : compétition pour avoir meilleures perfs
- Si beaucoup de clients ont des données biaisées, le modèle appris global sera biaisé

Ex : un modèle relié aux véhicules autonomes appris sur des véhicules thermiques. Fonctionne beaucoup moins bien sur véhicule électrique

=> Beaucoup de recherche sur la réduction des biais et des inégalités engendrées par l'apprentissage fédéré

*(Fair resource allocation in Federated Learning)*

# V. Pistes d'amélioration du secteur

## Personnalisation

Parfois, modèle global appris avec les données de tous n'est pas adapté

=> combinaison apprentissage fédéré + entraînement local : modèle global ré-entraîné avec données locales

=> Cela s'appelle la personnalisation

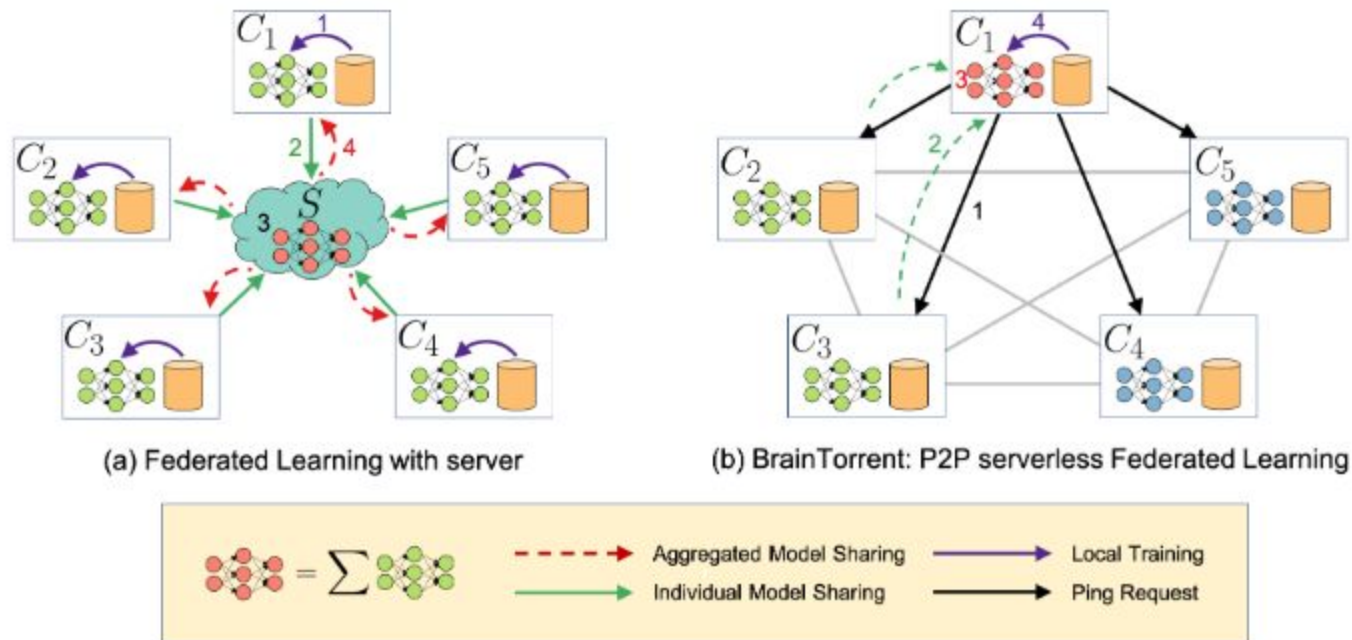
*(Personalized federated learning: A meta-learning approach)*



# V. Pistes d'amélioration du secteur


## Apprentissage sans serveur

Variante de l'apprentissage fédéré sans serveur



(BrainTorrent: A Peer-to-Peer Environment for Decentralized Federated Learning)

# Outils de veille utilisés





ÉCOLE  
**CENTRALE** LYON

36, avenue Guy de Collongue 69130 Écully - France  
+33 (0)4 72 18 60 00

[www.ec-lyon.fr](http://www.ec-lyon.fr)